

А.А. ВАГИЗОВ, А.Р. ЯКОВЛЕВ

kio77to@gmail.com, talamaka@yandex.ru,

Науч. руковод. – канд. техн. наук ВМиК Е.Ю. САЗОНОВА

Уфимский университет науки и технологий

СОВРЕМЕННЫЕ МЕТОДЫ КОМПЬЮТЕРНОГО ЗРЕНИЯ В МЕДИЦИНЕ: АНАЛИЗ АЛГОРИТМОВ И ПЕРСПЕКТИВЫ ПРИМЕНЕНИЯ

Аннотация: в статье проведен анализ современных исследований в области применения компьютерного зрения для решения задач медицинской диагностики. Рассмотрены ключевые направления: классификация, сегментация и детекция на медицинских изображениях. Особое внимание уделено возможностям и ограничениям глубокого обучения, включая сверточные нейронные сети (CNN), архитектуры U-Net, трансформеры, а также проблемам интерпретируемости и обобщаемости моделей. На примере открытого датасета рентгенограмм грудной клетки проведен сравнительный анализ эффективности архитектур VGG16, ResNet50 и EfficientNetB0 для задачи обнаружения пневмонии. Показано, что современные эффективные архитектуры (EfficientNetB0) показывают точность свыше 92% и являются предпочтительным выбором для подобных задач. Систематизированы основные вызовы и перспективные направления развития области.

Ключевые слова: компьютерное зрение, медицинская диагностика, глубокое обучение, сверточные нейронные сети, классификация изображений, сегментация, объяснимый искусственный интеллект (XAI), анализ медицинских изображений.

Введение

Современная медицинская диагностика все больше полагается на методы медицинской визуализации: рентгенографию, компьютерную (КТ) и магнитно-резонансную (МРТ) томографию, ультразвуковое исследование (УЗИ) и др. Рост объема данных и высокая нагрузка на врачей-рентгенологов стимулируют развитие систем автоматизированного анализа изображений на основе искусственного интеллекта (ИИ) и компьютерного зрения [1].

Наиболее значительный прогресс в этой области связан с глубоким обучением (deep learning), в частности, со сверточными нейронными сетями (CNN, Convolutional Neural Networks), которые показали выдающиеся результаты в задачах классификации, сегментации и детекции объектов на изображениях [2]. Однако внедрению таких систем в клиническую практику препятствуют ряд проблем: необходимость больших размеченных датасетов,

проблема «черного ящика», недостаточная обобщающая способность моделей и вопросы регуляторного одобрения [3].

Целью данного исследования является анализ современного состояния, ключевых методов и основных проблем в области компьютерного зрения для медицины, а также экспериментальная оценка эффективности стандартных архитектур CNN для задачи бинарной классификации.

Подход к компьютерному зрению в медицине

Для анализа современного состояния области был проведен обзор научных публикаций в базах данных IEEE Xplore, PubMed, arXiv.org и др. за последние 5 лет. Основное внимание уделено работам, посвященным применению CNN, U-Net и трансформеров в медицинской визуализации.

В практической части исследования для сравнительного анализа был выбран открытый датасет «Chest X-Ray Images (Pneumonia)» [4]. Датасет содержит 5856 рентгенограмм грудной клетки (1583 изображения — класс «NORMAL», 4273 — «PNEUMONIA»). Изображения были приведены к размеру 224x224 пикселей и нормализованы.

Для экспериментов были выбраны три предобученные на датасете ImageNet архитектуры: VGG16, ResNet50, EfficientNetB0

Для каждой архитектуры была заменена головная часть (fully connected layers) для решения задачи бинарной классификации. Использовался метод transfer learning и fine-tuning. Модели обучались с аугментацией данных (random rotations, shifts) для снижения риска переобучения. Оптимизатор — Adam, функция потерь — binary crossentropy. Для оценки использовались метрики: Accuracy, Precision, Recall, F1-Score.

Проведенный обзор позволил выделить доминирующие подходы:

- Классификация: наиболее распространены архитектуры семейств ResNet, DenseNet, EfficientNet и их модификации, используемые как в качестве feature extractors, так и с применением transfer learning [5].

- Сегментация: Архитектура U-Net и ее многочисленные модификации (например, 3D U-Net для объемных данных, nnU-Net для автоматической конфигурации) являются стандартом de facto для выделения областей интереса на медицинских изображениях [6].

- Детекция: Для локализации патологий применяются архитектуры типа R-CNN, YOLO и их производные, адаптированные для работы с медицинскими данными.

- Современные тренды: активно исследуется применение трансформеров (Vision Transformer, Swin Transformer) и гибридных моделей (например, TransUNet [7]), сочетающих в себе способность CNN к выделению локальных features и способность трансформеров улавливать глобальные контекстные зависимости.

Ключевыми проблемами области остаются:

- Нехватка данных: Разметка медицинских изображений требует экспертных знаний и дорогостояща.

— Смещение данных (Bias): Модели, обученные на данных одной больницы, часто плохо работают на данных другой из-за различий в оборудовании и протоколах [8].

— Интерпретируемость: для клиницистов критически важно понимать, на основании чего модель приняла решение, что стимулирует развитие методов Explainable AI (XAI) — Grad-CAM, LIME, SHAP [9].

Был проведен эксперимент с тремя архитектурами. Сравнительный анализ трех архитектур на датасете рентгенограмм показал следующие результаты (усредненные по validation set) (табл. 1)

Таблица 5

Сравнение метрик эффективности архитектур CNN

Архитектура	Acceracy	Precision	Recall	F1-Score
VGG16	0.87	0.89	0.93	0.91
ResNet50	0.91	0.93	0.95	0.94
EfficientNetB0	0.93	0.94	0.96	0.95

Как видно из таблицы, архитектура EfficientNetB0 показала наилучшие результаты по всем метрикам, продемонстрировав преимущество своего подхода к масштабированию и эффективному использованию параметров. ResNet50 показала близкие, но чуть более низкие результаты. VGG16, несмотря на свою историческую значимость, значительно уступает современным архитектурам, показывая большую склонность к переобучению и меньшую обобщающую способность.

Заключение

Проведенное исследование подтверждает, что методы компьютерного зрения на основе глубокого обучения являются мощным инструментом для автоматизации анализа медицинских изображений. Доминирующими подходами остаются сверточные нейронные сети и их архитектуры-наследники (U-Net, EfficientNet), хотя активно набирают популярность гибридные модели и трансформеры.

Экспериментальная часть работы demonstrated, что корректный выбор архитектуры (EfficientNet) позволяет достигать высокой точности (>92%) даже на относительно небольших датасетах с использованием методов transfer learning.

Перспективными направлениями для дальнейших исследований являются: развитие методов обучения с слабым присмотром (weak supervision) и самообучения (self-supervised learning) для преодоления нехватки данных, повышение надежности и обобщаемости моделей, а также дальнейшая разработка и интеграция методов объяснимого ИИ (XAI) для построения доверительных отношений между врачом и системой ИИ.

Библиографический список

1. Ranneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional Networks for Biomedical Image Segmentation. arXiv. <https://arxiv.org/abs/1505.04597>
2. Chen, J., Lu, Y., Yu, Q., Luo, X., Adeli, E., Wang, Y., ... & Zhou, Y. (2021). TransUNet: Transformers Make Strong Encoders for Medical Image Segmentation. arXiv. <https://arxiv.org/abs/2102.04306>
3. Wang, L., Lin, Z. Q., & Wong, A. (2020). COVID-Net: a tailored deep convolutional neural network design for detection of COVID-19 cases from chest X-ray images. Scientific Reports, 10(1), 19549. <https://www.nature.com/articles/s41598-020-76550-z>
4. Rajpurkar, P., Irvin, J., Zhu, K., Yang, B., Mehta, H., Duan, T., ... & Ng, A. Y. (2017). CheXNet: Radiologist-Level Pneumonia Detection on Chest X-Rays with Deep Learning. arXiv. <https://arxiv.org/abs/1711.05225>
5. Isensee, F., Jaeger, P. F., Kohl, S. A., Petersen, J., & Maier-Hein, K. H. (2021). nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation. Nature Methods, 18(2), 203-211. <https://www.nature.com/articles/s41592-020-01008-z>
6. Litjens, G., Kooi, T., Bejnordi, B. E., Setio, A. A. A., Ciompi, F., Ghafoorian, M., ... & Sánchez, C. I. (2017). A survey on deep learning in medical image analysis. Medical Image Analysis, 42, 60-88. <https://www.sciencedirect.com/science/article/abs/pii/S1361841517301135>
7. Reyes, M., Meier, R., Pereira, S., Silva, C. A., Dahlweid, F. M., Tengg-Kobligk, H., ... & Wiest, R. (2020). On the Interpretability of Artificial Intelligence in Medical Image Analysis: Fundamentals, Theory, and Applications. IEEE Reviews in Biomedical Engineering. <https://ieeexplore.ieee.org/document/9125707>
8. Бибиков О.С. Применение искусственного интеллекта для диагностики рака кожи: преимущества и вызовы // Вестник современных технологий. – 2021. – № 3(44). – С. 45-52. <https://cyberleninka.ru/article/n/primenenie-iskusstvennogo-intellekta-dlya-diagnostiki-raka-kozhi-preimuschestva-i-vyzovy>
9. Zech, J. R., Badgeley, M. A., Liu, M., Costa, A. B., Titano, J. J., & Oermann, E. K. (2018). Variable generalization performance of a deep learning model to detect pneumonia in chest radiographs: a cross-sectional study. PLOS Medicine, 15(11), e1002683. <https://journals.plos.org/plosmedicine/article?id=10.1371/journal.pmed.1002683>
10. Çiçek, Ö., Abdulkadir, A., Lienkamp, S. S., Brox, T., & Ronneberger, O. (2016). 3D U-Net: learning dense volumetric segmentation from sparse annotation. In International Conference on Medical Image Computing and Computer-Assisted Intervention (pp. 424-432). Springer, Cham. https://link.springer.com/chapter/10.1007/978-3-319-46723-8_49
11. Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is All You Need. Advances in Neural Information Processing Systems, 30, 5998-6008.

<https://papers.nips.cc/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html>

12. He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep Residual Learning for Image Recognition. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (pp. 770-778). <https://arxiv.org/abs/1512.03385>

13. Huang, G., Liu, Z., Van Der Maaten, L., & Weinberger, K. Q. (2017). Densely Connected Convolutional Networks. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (pp. 4700-4708). <https://arxiv.org/abs/1608.06993>

14. Hatamizadeh, A., Tang, Y., Nath, V., Yang, D., Myronenko, A., Landman, B., ... & Xu, D. (2022). UNETR: Transformers for 3D Medical Image Segmentation. In Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (pp. 574-584). <https://arxiv.org/abs/2103.10504>

15. Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., & Batra, D. (2017). Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization. In Proceedings of the IEEE International Conference on Computer Vision (pp. 618-626). <https://arxiv.org/abs/1610.02391>

16. Irvin, J., Rajpurkar, P., Ko, M., Yu, Y., Ciurea-Ilcus, S., Chute, C., ... & Ng, A. Y. (2019). CheXpert: A Large Chest Radiograph Dataset with Uncertainty Labels and Expert Comparison. In Proceedings of the AAAI Conference on Artificial Intelligence, 33(01), 590-597. <https://arxiv.org/abs/1901.07031>

17. Esteva, A., Kuprel, B., Novoa, R. A., Ko, J., Swetter, S. M., Blau, H. M., & Thrun, S. (2017). Dermatologist-level classification of skin cancer with deep neural networks. *Nature*, 542(7639), 115-118. <https://www.nature.com/articles/nature21056>

18. Antonelli, M., Reinke, A., Bakas, S., Farahani, K., Kopp-Schneider, A., Landman, B. A., ... & Heller, N. (2022). The Medical Segmentation Decathlon. *Nature Communications*, 13(1), 4128. <https://www.nature.com/articles/s41467-022-30695-9>

19. Oktay, O., Schlemper, J., Folgoc, L. L., Lee, M., Heinrich, M., Misawa, K., ... & Rueckert, D. (2018). Attention U-Net: Learning Where to Look for the Pancreas. *arXiv preprint arXiv:1804.03999*. <https://arxiv.org/abs/1804.03999>

20. McKinney, S. M., Sieniek, M., Godbole, V., Godwin, J., Antropova, N., Ashrafian, H., ... & Shetty, S. (2020). International evaluation of an AI system for breast cancer screening. *Nature*, 577(7788), 89-94. <https://www.nature.com/articles/s41586-019-1799-6>

© Вагизов А.А., Яковлев А.Р., 2025